

1. 最速下降法

基本思想：最速下降法通过迭代的方式求函数 $f(x)$ 的最优解，给定一个初始点，通过迭代找到下一个点，我们希望找到的下一个点能比上一个点有更优的函数值。给定点 x_k ，点 x_k 处的负梯度方向为最速下降方向，至少在点 x_k 的临近范围内是这样的。所以我们可以选择在点 x_k 处选择搜索方向：

$$p_k = -\nabla f(x_k)$$

在选定了搜索方向之后我们就可以沿着搜索方向进行搜索，然后选择点 x_{k+1} ，其中

$$x_{k+1} = x_k - t_k \nabla f(x_k)$$

其中 t_k 为沿负梯度方向的搜索距离，我们称为步长因子。在知道迭代公式之后，我们希望得到步长因子 t_k 能够满足

$$f(x_k - t_k \nabla f(x_k)) = \min f(x_k - t \nabla f(x_k))$$

即我们希望 x_{k+1} 为搜索方向上的最小点。

算法描述：

(1) 选择初始点 x_0 ；计算 $f_0=f(x_0)$ 以及梯度 $g_0=g(x_0)$ ； $k=0$

(2) 做线搜索 $x_{k+1} = x_k - t_k \nabla f(x_k)$ ；计算

$$f_{k+1}=f(x_{k+1}), g_{k+1}=g(x_{k+1});$$

(3) 判断是否满足终止条件，满足输出 x_{k+1} ，否则 $k=k+1$ ，转

2.

常见的终止条件如函数值的变化范围小于阈值 ϵ 时终止。我们可以知道最速下降法关键步骤是求解每一步的步长因子 t_k ，而对于

正定二次函数：


$$f(x) = \frac{1}{2}x^T Qx + b^T x + c$$

由于最速下降法的连续两次的搜索方向是垂直的，所以可以计算得：

$$t_k = \frac{g_k^T g_k}{g_k^T Q g_k}$$

上式便是最速下降法应用于正定二次函数时的步长迭代公式。

实验过程中锯齿现象如图：



2. 牛顿法

牛顿法的基本思想是利用迭代点 x_k 处的一阶导数(梯度)和二阶导数(Hessen 矩阵)对目标函数进行二次函数近似，然后把二次模型的极小点作为新的迭代点，并不断重复这一过程，直至求得满足精度的近似极小值。

基本牛顿法是一种是利用导数的算法，它每一步的迭代方向都是

沿着当前点函数值下降的方向。对于一个需要求解的优化函数 $f(x)$ ，求函数的极值的问题可以转化为求导函数 $f'(x) = 0$ 。对函数 $f(x)$ 进行泰勒展开到二阶，得到

$$f(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{1}{2}f''(x_k)(x - x_k)^2$$

对上式求导并置 0，则有


$$f'(x_k) + f''(x_k)(x - x_k) = 0$$

得： $x = x_k - \frac{f'(x_k)}{f''(x_k)}$ ，这就是牛顿法的更新公式。

算法流程：

- (1) 给定终止条件 ε ，初始点 x_0 ， $k=1$ ；
- (2) 计算 $g_k = \nabla f(x_k)$ ，若 $\|g_k\| \leq \varepsilon$ ，停止，输出 $x^* \approx x_k$ ；
- (3) 计算 $G_k = \nabla^2 f(x_k)$ ，并求解线性方程组得到解 $d_k: G_k d_k = -g_k$ ；
- (4) 令 $x_{k+1} = x_k + d_k$ ， $k=k+1$ ，并转 2.

算法运行示意图：



3. 带线搜索的牛顿法

回溯线搜索：回溯线搜索是一种在求解无约束凸优化问题中，调整搜索步长非常简单有效的方法，也是实际应用中常用的方法。

回溯线搜索的算法流程为：

输入：当前点 x ，搜索方向 ∇x ，参数 $\alpha \in (0, 0.5)$, $\beta \in (0, 1)$ ；

输出：步长 t 。

(1) 令 $t=1$ ；

(2) 如果 $f(x + t\Delta x) > f(x) + \alpha t \nabla f(x)^T \Delta x$, $t = \beta t$ ；

(3) 重复第 2 步，直到 $f(x + t\Delta x) \leq f(x) + \alpha t \nabla f(x)^T \Delta x$ ；

带线搜索的牛顿法：基本牛顿法有两个前提：小的增量 s_k 和 G_k 正定。当迭代过程中条件不满足时，可以用回溯线搜索方法对牛顿法进行修正，原理如下：

(1) 搜索方向的修正：
$$p_k = \begin{cases} -(G_k)^{-1} g_k, & G_k \text{ 正定} \\ -g_k & \text{否则} \end{cases}$$

(2) 步长的修正： $x_{k+1} = x_k + t * p_k$ 其中 t 是回溯线搜索返回的数值， p_k 为搜索方向。

算法大致流程如下：

(1) 给定终止条件 ε ，初始点 x_0 ， $k=1$ ；

(2) 计算 $g_k = \nabla f(x_k)$ ，若 $\|g_k\| \leq \varepsilon$ ，停止，输出 $x^* \approx x_k$ ；

(3) 计算 $G_k = \nabla^2 f(x_k)$ ，判断 G_k 的正定性，选择合适的搜索

方向
$$p_k = \begin{cases} -(G_k)^{-1} g_k, & G_k \text{ 正定} \\ -g_k & \text{否则} \end{cases}$$

(4) 运行回溯线搜索方法 `backtrackingls` 得到最佳步长 t 。

(5) 令 $x_{k+1} = x_k + t * p_k$ ， $k=k+1$ ，并转 2。

4. 回溯线搜索的最速下降法：

最速下降方法（梯度下降法或者梯度法）：

$$\begin{cases} \text{minimize } p^T g^k \\ \text{subject to } \|p\|_2 = 1 \end{cases}, \text{ 每次迭代计算梯度和步长。如果 } f(x)$$

连续可微有下界, 且 $g(x)$ 是连续的, 以负梯度作为搜索方向。

步长可选择回溯线搜索确定: $x^{k+1} = x^k - \alpha_k g^k$.

算法的大致流程如下：

(1) 选择初始点 x_0 ; 计算 $f_0=f(x_0)$ 以及梯度 $g_0=g(x_0)$; $k=0$

(2) 运行回溯线搜索方法, 得到 t_k ;

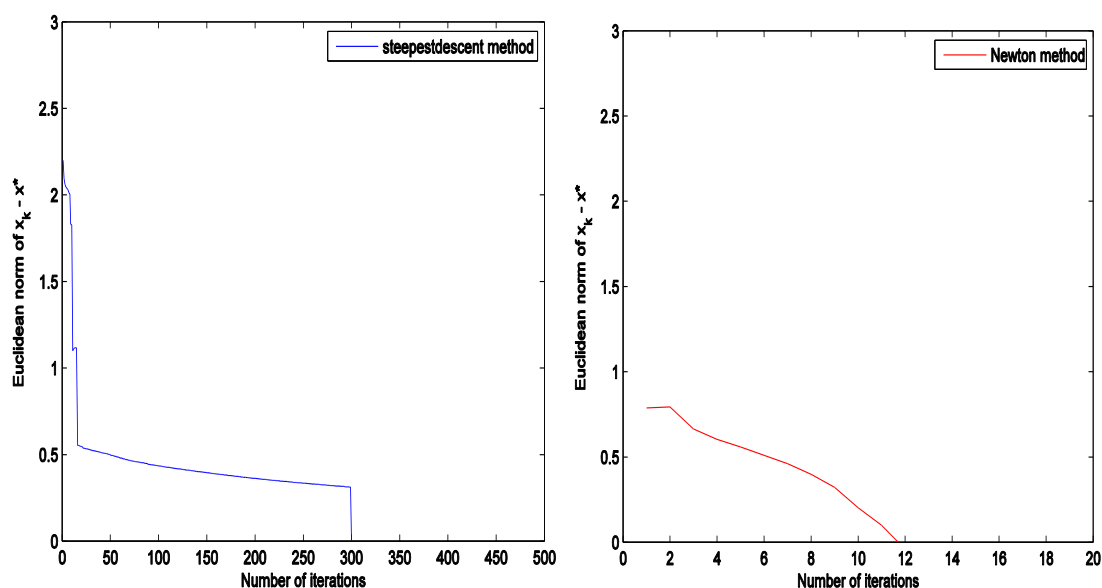
(3) 做线搜索 $x_{k+1} = x_k - t_k \nabla f(x_k)$; 计算

$$f_{k+1}=f(x_{k+1}), g_{k+1}=g(x_{k+1});$$

(4) 判断是否满足终止条件, 满足输出 x_{k+1} , 否则 $k=k+1$, 转

2.

带回溯线搜索的最速下降法和牛顿法运行示意图如下：



5. 共轭梯度法

共轭梯度法是一种求解对称正定线性方程组 $Ax=b$ 的迭代方法。事实上，求解 $Ax=b$ 的解等价求解： $\min \|Ax - b\|_2^2$ ，将其展开后等价于 $\min \frac{1}{2} x^T A^T A x - b^T A x$ ，即原问题转换为一个二次规划问题。共轭梯度法是介于梯度下降法与牛顿法之间的一个方法，是一个一阶方法。它克服了梯度下降法收敛慢的缺点，又避免了存储和计算牛顿法所需要的二阶导数信息。在 n 维的优化问题中，共轭梯度法最多 n 次迭代就能找到最优解（是找到，不是接近），但是只针对二次规划问题。共轭梯度法的思想就是找到 n 个两两共轭的共轭方向，每次沿着一个方向优化得到该方向上的极小值，后面再沿其它方向求极小值的时候，不会影响前面已经得到的沿哪些方向上的极小值，所以理论上对 n 个方向都求出极小值就得到了 n 维问题的极小值。

目标函数标准形式为： $\min \frac{1}{2} x^T Q x - b^T x$ ，我们需要找到 n 个相互 Q -conjugate 的基向量 d_1, d_2, \dots, d_n ，它们相互共轭且线性无关。因此空间中任意向量 x 都可以用这组基向量表示：

$x = \sum_{i=1}^n a_i d_i$ ，目标函数可以化简为：

$$\min_{a_1 \dots a_n} \frac{1}{2} \sum_{i=1}^n (a_i^2 d_i^T Q d_i - a_i b^T d_i)$$

求最小值，直接求导可以得到：

$$a_i = \frac{b^T d_i}{d_i^T Q d_i}$$

所以最优解 $x^* = \sum_{i=1}^n a_i d_i$ 。

现在，我们只需要构建 Q 向量组 d_1, d_2, \dots, d_n 。有一种称为 Gram-Schmidt 过程的算法可以用来找到这组向量。在实际算法实现中，我们往往是边求 a_i ，边求 d_i 。下面给出完整的共轭梯度算法。

- (1) 初始化 x_0 ，计算 $g_0 = G * x_0 - b$;
- (2) 设置 $p_0 = -g_0$, $k=0$
- (3) 当残差 $\|g_k\| > \varepsilon$, 进行如下循环:

$$D = G * p_k;$$

$$a_k = \frac{g_k^T g_k}{p_k^T D};$$

$$x_{k+1} = x_k + a_k p_k;$$

$$g_{k+1} = g_k + a_k * D;$$

$$\beta_{k+1} = \frac{g_{k+1}^T g_{k+1}}{g_k^T g_k};$$

$$p_{k+1} = -g_{k+1} + \beta_{k+1} p_k;$$

$$k = k + 1;$$

- (4) 返回 x_k 作为 x^* ;

题意中数据迭代次数变化如下:

5 7

8 20

12 39

20 63

随着 n 的增大，迭代次数增加。

6. 带线搜索的高斯牛顿法

高斯-牛顿迭代法 (Gauss-Newton iteration method) 是非线性回

归模型中求回归参数进行最小二乘的一种迭代方法，该法使用泰勒级数展开式去近似地代替非线性回归模型，然后通过多次迭代，多次修正回归系数，使回归系数不断逼近非线性回归模型的最佳回归系数，最后使原模型的残差 r 平方和达到最小。其直观思想是先选取一个参数向量的参数值 β ，若函数 $f_t(X_t, \beta)$ 在 β_0 附近有连续二阶偏导数，则在 β_0 的邻域内可近似地将 $f_t(X_t, \beta)$ 看作是线性，因而可近似地用线性最小二乘法求解。

令 $f(x) = \frac{1}{2} \sum_{i=1}^m r_i(x)^2$ ，则 $g(x) = A(x)^T r(x)$ ， $G(x) = A(x)^T A(x) + \sum_{i=1}^m r_i(x) \nabla^2 r_i(x)$ 。通常 $r_i(x)$ 都很小，所以 $G(x) \approx A(x)^T A(x)$ 。基本高斯牛顿法的迭代为：

(1) 通过 $A_k^T A_k s = -A_k^T r_k$ ，求解 s_k ；

(2) $x_{k+1} = x_k + s_k$


带回溯线搜索的 GN 法：

主要区别于 GN 法是搜索步长的加入，流程如下：

(1) 求解 $A_k^T A_k s = -A_k^T r_k$ ；

(2) 用回溯线搜索得到最佳步长 t_k ；

(3) $x_{k+1} = x_k + t_k s_k$



算法运行示意图如下：

7. 基于 Steihaug 共轭梯度法的信赖域法：

因为共轭梯度法在迭代过程中产生的近似解的范数在增大，因此如果迭代满足 $\|x^{i+1}\|_2 > \Delta$ ，则在求解信赖域问题的解必然在边界上，即 $\|s^*\|_2 = \Delta$ 。如果存在 i 满足 $p_i^T B p_i \leq 0$ 或者 $\|x^i + \alpha_i p_i\|_2 > \Delta$ ，则算法应该在第 i 次迭代后停止。在这两种情况下，最简单的终止条件策略是停在点 $s' = x^i + \alpha_B p_i$ ，其中 α_B 是二次方程：

$$\|x^i + \alpha p_i\|_2^2 = \Delta^2$$

的根，且点 s' 满足信赖域条件。

基于 Steihaug 共轭梯度法的信赖域法的算法流程如下：

- (1) 设置阈值 ϵ ， $x_0=0$ ， $r_0=g$ ， $p_0=-g$ ；
- (2) 如果 $\|r_0\| < \epsilon$ ， $s' = x_0$ ，退出；
- (3) 执行以下循环(循环变量 j)，直到满足条件退出：

[1] 如果 $p_j^T B p_j \leq 0$ ，解 $\|x_j + \alpha p_j\|_2^2 = \Delta^2$ ，并计算 s' 后，退出。

$$[2] \alpha_j = \frac{r_j^T r_j}{p_j^T B p_j}; x_{j+1} = x_j + \alpha_j p_j;$$

如果 $\|x^{i+1}\|_2 > \Delta$ ，解 $\|x_j + \alpha p_j\|_2^2 = \Delta^2$ ，并计算 s' 后。退出；

$$[3] r_{j+1} = r_j + \alpha_j B p_j;$$

如果 $\|r_{i+1}\| < \epsilon$ ，则 $s' = x_{j+1}$ ，退出。

$$[4] \beta_{j+1} = \frac{r_{j+1}^T r_{j+1}}{r_j^T r_j};$$

$$[5] p_{j+1} = -r_{j+1} + \beta_{j+1} p_j;$$